

## 1. Гайки и болты

Пусть нам дано 2 массива: с гайками (A) и болтами (B). Элемент каждого массива - номер пары, к которой принадлежит гайка или болт (пусть с ростом номера у нас увеличивается диаметр болта и гайки - тогда можно будет сравнивать болты и гайки разных размеров и понимать, у кого номер пары больше, а у кого - меньше). Наша задача - построить отображение, переводящее номер пары в пару индексов, соответствующих элементам в исходных массивах.

В каждом массиве заменим на пары  $X[i] \rightarrow (i, X[i])$ ,  $X \in A, B$ . Потом реализуем быструю сортировку, в которой опорный элемент будем брать из одного массива и сравнивать его с элементами другого по 2 значению в парах:

1. Случайным образом выберем гайку  $A[i]$ , используем ее как опорный и сделаем **Partition** в массиве болтов B, сравниваясь с выбранной гайкой. Т.е. переставим болты так, чтобы болты с меньшим номером пары лежали левее болта, соответствующего выбранной гайке, с права - больше.
2. Затем сделаем **Partition** в массиве гаек, используя болт из предыдущего пункта.
3. Рекуррентно вызываемся в каждую половинку и аналогично делаем **Partition** в соответствующих подмассивах болтов и гаек.

В результате мы совместим массивы A и B и для каждого номера пары теперь можно сопоставить номер гайки и болта из исходного массива.

## 2. Детерменированная $k$ -порядковая статистика

- (а) Действуем как на паре - разделим исходный массив A на блоки по 7 частей (считаем длину массива  $n = 7l$ ). Хотим найти элемент, который гарантированно разделит A в какое-то число раз. Пусть это будет медиана среди медиан в блоках по 7. Тогда за  $O(n)$  находим медианы в блоках, их  $\frac{n}{7}$  штук, тогда в каждом блоке медиана не меньше чем 4 элемента (ключая саму медиану), а потом среди медиан рекуррентно за  $T(n/7)$  ищем медиану и она не меньше чем половина от набора медиан. Получаем

$$n_1 = \frac{n}{14} \cdot 4 = \frac{2n}{7}$$

Значит, найдя медиану медиан, мы гарантированно отсечем  $\frac{2n}{7}$  элементов, когда сделаем **Partition**, и будем искать порядковую статистику в оставшемся куске из  $\frac{5n}{7}$  элементов. Тогда рекуррентное соотношение:

$$T(n) \leq T(5n/7) + T(n/7) + O(n)$$

Как и на паре легко проверить, что оно дает  $T = O(n)$ . Если известно, что  $T(m) \leq Cm$  для  $m < n$ , то

$$T(n) \leq C \frac{5n}{7} + C \frac{n}{7} + C_1 n = n \left( \frac{6}{7} C + C_1 \right) \leq Cn$$

для  $C_1 \leq C/7$ .

- (b) Теперь будем делить на блоки по 3 (не умаляя общности, считаем что  $n = 3l$ ). Тогда при поиске медианы медиан в каждом блоке медиана не меньше чем 2 элемента, всего медиан  $\frac{n}{3}$  штук, а медиана медиан - меньше чем половина последних. Тогда мы гарантированно будем больше и меньше чем

$$n_1 = \frac{n}{3} \cdot \frac{2}{2} = \frac{n}{3}$$

элементов. Получаем рекуррентное соотношение:

$$T(n) = T(2n/3) + T(n/3) + O(n)$$

Видно, что мы уже не получим  $T(n) = O(n)$ , потому что на каждом шаге мы будем совершать  $O(n)$  операций (в отличие от предыдущего случая, когда на каждом шаге число операций уменьшается и получается геометрическая прогрессия). Получается, что асимптотика должна иметь вид

$$T(n) = N(n)O(n),$$

где  $N(n)$  - сколько шагов сделает алгоритм. По сути, это число уровней в дереве рекурсии. Его просто найти - это  $N(n) = \log_{3/2}(n)$ . Получаем асимптотику

$$T(n) = \Theta(n \log(n))$$

### 3. $k$ -ближайших соседей в метрике

- (a)  $d(x, \text{median}) = |\text{pos}(x) - \text{pos}(\text{median})|$

Из прошлого семинара узнали (5 задача), что можно за  $O(n)$  искать  $k$ -порядковую статистику с помощью модифицированного MergeSort.

1. Сначала в исходном массиве **A** найдем за  $O(n)$  медиану, при этом мы фактически сделаем **Partition** и левая часть массива будет меньше **median**, а правая - больше.

2. Затем в левой половине за  $O(n)$  найдем  $(m - k/2)$ -порядковую статистику (обозначим  $a$ ), а в правой -  $(m + k/2 + (k \bmod 2))$ -порядковую статистику (обозначим  $b$ ). При этом при их поиске мы в каждой половине делаем **Partition**, поэтому все  $x$ , левее  $a$ , обязательно  $x < a$ , а те  $x$ , которые правее  $b$ :  $b < x$ . Тем самым элементы  $[a...m]$  и  $(m...b]$  (они неотсортированы) являются ближайшими к **median** в осортированном массиве.

В результате вокруг медианы мы получим два отрезка суммарной длины  $k$ , с одной стороны ближайших и меньших **median**, с другой - ближайших и больших.

- (b)  $d(x, \text{median}) = |x - \text{median}|$

Как в предыдущем пункте находим медиану. Нам надо найти в массиве  $k$  элементов, чтобы они были как можно ближе к **median**, т.е.

$$x \in \mathbf{A} : d(x, \text{median}) = |x - \text{median}| \rightarrow \min$$

Тогда пройдемся по массиву и вместо каждого значения  $x$  запишем пару  $(x, d(x, \text{median}))$ . Значит, для того чтобы найти нужные элементы, надо найти  $(k + 1)$ -порядковую статистику в массиве по 2му аргументу (у нас в массиве будет ноль, соответствующий **median** - он нам не нужен, поэтому возьмем на 1 элемент больше). Тем самым мы найдем  $k$  элементов, которые минимально отличаются от медианы

### 4. (\*)

## 5. Найти $k$ минимумов

Прочитаем первые  $2k$  массивов и найдем среди них за  $O(2k)$  медиану. Слева от нее будут элементы, меньше чем медиана, справа- больше. Выкинем из этого массива последние  $k$  элементов и прочитаем следующие  $k$ , найдем медиану и снова выкинем последние  $k$  элементов. В результате мы совершим  $n/k$  шагов, на каждом из которых мы за  $O(k)$  находим медиану и отбрасываем элементы, большие ее. Тем самым в конце алгоритма мы получим  $k$  минимумов за  $O(n)$  времени и  $O(k)$  памяти.

## 6. Число сравнений

(а) Для того, чтобы определить максимум необходимо, чтобы каждое число поучаствовало в сравнении хотя бы один раз, иначе мы не будем иметь информации о об этом числе. Поскольку у в сравнении участвует 2 числа, то число сравнений должно быть не меньше чем  $n/2$ , иначе мы забыли сравнить какое-то число.

(b) Пусть нам дан массив  $\{x_1, x_2, \dots, x_n\}$  размера  $n$ . Чтобы найти максимум, возьмем первые два элемента, сравним их и выберем максимум (обозначим его  $m_1$ ) Затем возьмем следующий элемент в массиве,  $x_3$  и сравним его с  $m_1$ . Обозначим максимум из последней пары  $m_2$  и сравним со следующим числом и тд. Продолжая в том же духе, мы переберем все элементы и сделаем  $n - 1$  сравнение. Полученное число будет максимумом, поскольку на каждом  $k$ -м шаге алгоритма мы сравниваем  $x_k$  и  $m_{k-2}$ , который является максимумом среди предыдущих  $k-1$  чисел. Тем самым найдем  $m_{k-1}$ , т.е. максимум среди первых  $k$  элементов. Перебрав все числа мы найдем максимум во всем массиве.

Нельзя найти максимум за меньшее число сравнений, потому что у нас тогда нарушится цепочка сравнений. Т.е. если мы одно сравнение уберем, то у нас станет 2 группы чисел, в которых мы знаем, как числа соотносятся друг с другом, но между этими группами у нас нет связи и поэтому мы не можем сравнить элементы разных групп. По сути, если числа представить как вершины графа, а ребра - как сравнение пары чисел, то для того, чтобы найти максимум, нам надо получить связный граф, потому что нам надо иметь информацию о том, как соотносятся любые 2 числа, т.е. уметь проходить от одной вершины к другой. А условие на минимальное число ребер решается тем, что граф - дерево, а у него  $n-1$  ребро.

## 7. Число сравнений (\*)

(а) Поскольку у нас  $2n$  чисел, разобьем их на  $n$  пар и проведем сравнения, после чего получим группы из  $n$  максимумов и  $n$  минимумов. Так как нам надо найти максимум и минимум среди всех  $2n$  чисел, то максимум должен быть в группе с  $n$  максимумами, а минимум - с минимумами. Поэтому в первой группе мы ищем максимум, а во второй - минимум. Для этого в каждой группе, по предыдущей задаче, нам понадобится не более чем  $n - 1$  сравнение. Тем самым мы находим нужные элементы за  $3n - 2$  сравнения.

(b) Можно еще придумать другой способ. Возьмем первые 2 числа, сравним их за 1 операцию и получим текущий максимум и минимум. Осталось  $2n - 2$  элемента. Затем на каждом следующем шаге будем брать пару чисел, ее сравнивать и максимум из пары сравнивать с текущим максимумом, а минимум - с текущим минимумом, и в случае чего обновлять. Тогда мы будем делать по 3 сравнения. Здесь не сделать 2, потому что из новой пары не понятно кто из них больше, а кто - меньше, чтобы потом обновить текущие значения минимума и максимума. Если брать за раз больше элементов, например,  $k$ , то надо будет на каждом шаге делать  $N(k)$  сравнений и еще 2 для обновление текущих значений, в итоге  $2 + N(k)$ . Тогда формула для общего числа сравнений:

$$N(n) = 1 + \frac{2n - 2}{k} \cdot (2 + N(k))$$

Я не успеваю это оценить, почему надо брать  $k = 2$ , потому что осталось 5 минут до дедлайна, но по идее должно получиться, что для того, чтобы  $N(n)$  было минимальным, надо сделать  $k = 2$ , т.е. брать по 2 значения. Таким образом, получается  $N_{min} = 3n - 2$ .